

2021

人工智慧期末專題

C N N
陳 芮 窜

CONTENTS

- 1 資料蒐集處理**
資料的蒐集及人工前處理
- 2 程式前處理**
在程式中的讀檔及前處理
- 3 程式訓練**
70%的model訓練及成果展現(切出20%驗證)
- 4 程式測試**
30%的測試結果去跑另一個測試程式



01

資料蒐集處理

資料蒐集處理

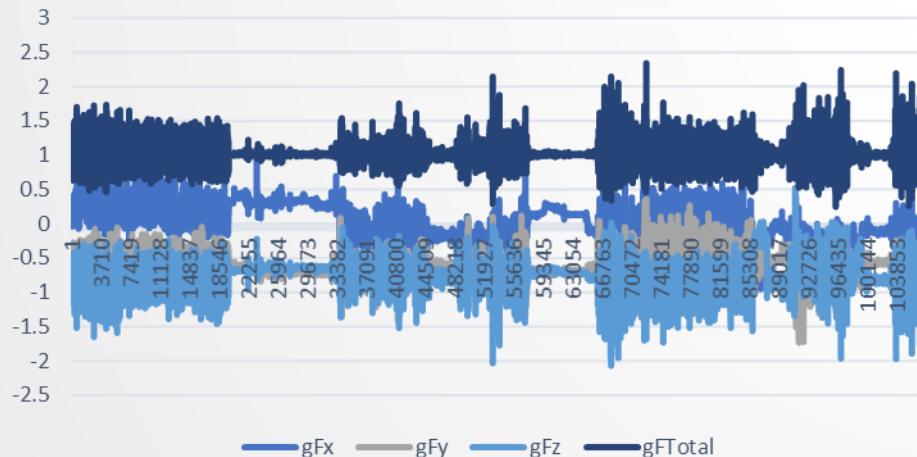
我先將label項新增進我們的csv檔中(如右圖所示)，照著之前上課交的步驟。

並將兩天的資料丟入data(沒有按照順序)，以及一天的資料丟進testData(如下兩圖所示)。

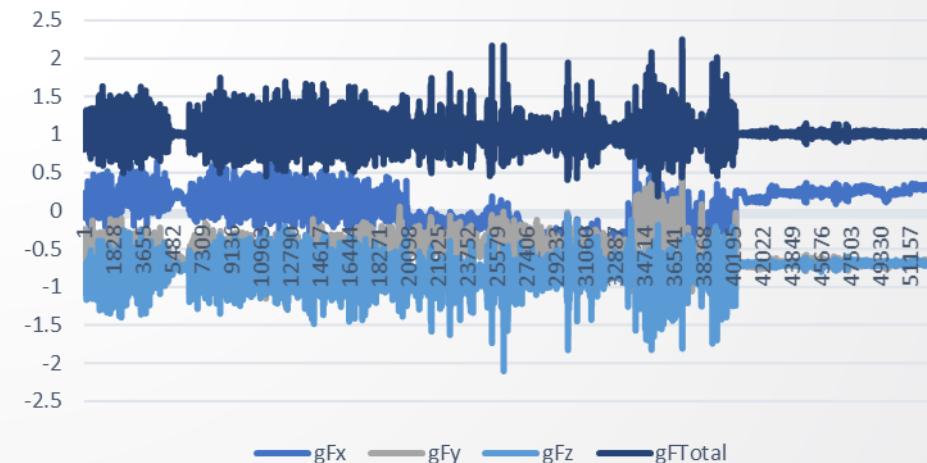
我並沒有平均，我使用原資料，其餘前處理皆於程式內完成。

	A	B	C	D	E	F
1	time	gFx	gFy	gFz	gFTotal	label
2	0.003508	-0.003	-0.32	-0.738	0.804	walk
3	0.011283	-0.004	-0.336	-0.731	0.805	walk
4	0.021508	0.008	-0.361	-0.725	0.81	walk
5	0.031771	0.038	-0.393	-0.727	0.827	walk
6	0.041599	0.067	-0.415	-0.754	0.863	walk
7	0.05201	0.082	-0.43	-0.781	0.895	walk
8	0.062266	0.098	-0.459	-0.783	0.913	walk
9	0.094684	0.073	-0.431	-0.8	0.912	walk
10	0.095028	0.073	-0.431	-0.8	0.912	walk

data的總資料



testData





02

程式前處理

程 式 前 處 理

```
19 processedList = []
20 tempI = 0
21 # 這邊下面在進行讀檔。
22 with open("data.csv", "r") as f:
23     for line in f:
24         sepline = line.split(",")
25         sepline[5] = sepline[5].replace("\n", "")
26         # 第一行標籤忽略
27         if tempI == 0:
28             tempI = 1
29             continue
30         temp = [sepline[0], sepline[1], sepline[2], sepline[3], sepline[4], sepline[5]]
31         processedList.append(temp)
32 # 這邊再將資料分成time , x , y , z ,total ,label的標籤
33 columns = ['time', 'x', 'y', 'z', 'total', 'label']
34 data = pd.DataFrame(data = processedList, columns = columns)
35 data = bq.DataFrame(data = processedList, columns = columns)
36 columns = ['time', 'x', 'y', 'z', 'total', 'label']
37 # 將標籤時間，X，Y，Z，總數，Label存入到df中
38 df = pd.DataFrame(processedList, columns)
```

讀檔

這邊是把檔案全部讀取進來，放進processedList裡面。

1

程 式 前 處 理

```
44 data['x'] = data['x'].astype('float')
45 data['y'] = data['y'].astype('float')
46 data['z'] = data['z'].astype('float')
47 Fs = 100 # Hz的數字。
48 frame_size = Fs*2 # 200 # 乘以二是為了兩秒。
49 hop_size = Fs*1 # 100 # 跳躍點，為了重疊資料而生。
50 activities = data['label'].value_counts().index
51 # 把三類的資料放進activities
52 # 把三類的資料放進activities
53 activities = data['label'].value_counts().index
```

2

轉換格式，放進變數
將Object型態轉換成float
把label放進 activities

3

設定參數
Fs為Hz,
frame_size為頻率,
hop_size為跳躍點，讓資料重疊。

程 式 前 處 理

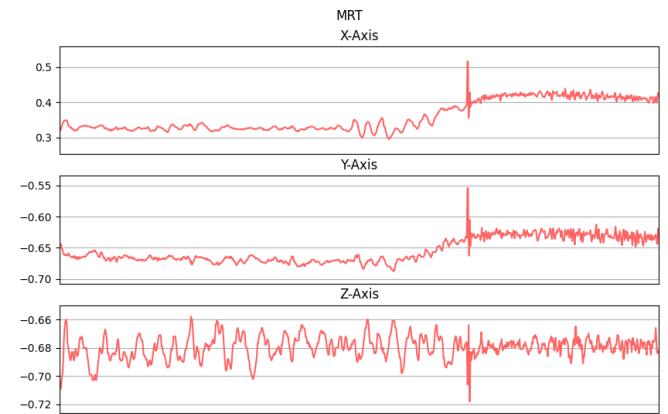
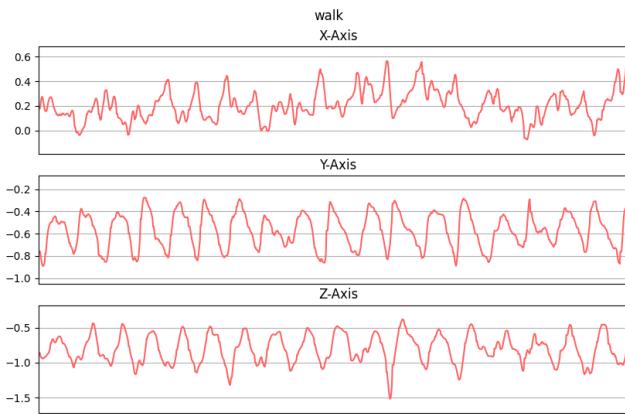
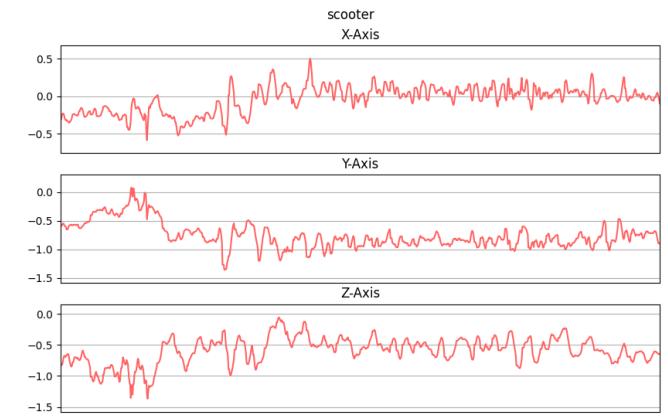
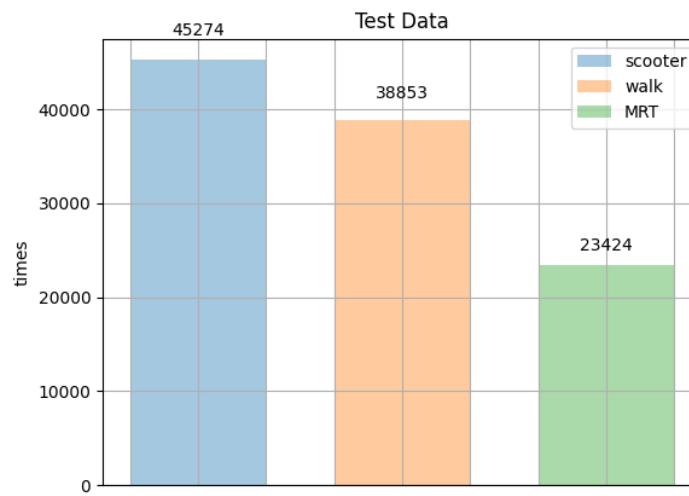
```
54 def plot_activity(activity, data):
55     fig, (ax0, ax1, ax2) = plt.subplots(nrows=3, figsize=(10, 6), sharex=True)
56     plot_axis(ax0, data['time'], data['x'], 'X-Axis')
57     plot_axis(ax1, data['time'], data['y'], 'Y-Axis')
58     plot_axis(ax2, data['time'], data['z'], 'Z-Axis')
59     plt.subplots_adjust(hspace=0.2)
60     fig.suptitle(activity)
61     plt.subplots_adjust(top=0.90)
62     plt.show()
63
64 def plot_axis(ax, x, y, title):
65     ax.plot(x, y, 'g')
66     ax.set_title(title)
67     ax.xaxis.set_visible(False)
68     ax.set_xlim([min(x), max(x)])
69     ax.set_ylim([min(y) - np.std(y), max(y) + np.std(y)])
70     ax.grid(True)
71 # 這邊上面都在做畫圖的function，不贅述。
72
73 for activity in activities:
74     data_for_plot = data[(data['label'] == activity)][:Fs*10]
75     plot_activity(activity, data_for_plot)
76 # 這邊再畫圖
77
78 # 總彙量圖
79 plot_activity('activity1', data)
80 plot_activity('activity2', data)
81
82 for activity in activities:
83
84
85
86
87
88
89
90
91
92
93
94
95
96
97
98
99
```

4

畫圖

畫類似於前面的圖表去確認，
下一頁為圖表。

Data圖表化



程 式 前 處 理

```
78 df = data.drop(['total','time'], axis = 1).copy()
79 # 把不需要的值丢掉
80 walk = df[df['label']=='walk'].copy()
81 scooter = df[df['label']=='scooter'].copy()
82 MRTt = df[df['label']=='MRT'].copy()
83 # 把df的參數載入
84
85 balanced_data = pd.DataFrame()
86 balanced_data = balanced_data.append([walk, scooter, MRTt])
87 # 放進一個變數中
88
89 label = LabelEncoder()
90 balanced_data['label'] = label.fit_transform(balanced_data['label'])
91 # 把label變成 0,1,2
92
93 X = balanced_data[['x', 'y', 'z']]
94 y = balanced_data['label']
95 # 把值存入X,y
96 scaler = StandardScaler()
97 X = scaler.fit_transform(X)
98 # 計算均值何方差，然後標準化。
99
100 # 將標準化後的數字，塞回原本的欄位。
101 X = scaler.transform(X)
102 scaler = StandardScaler()
103 # 檢查X是否
104 X = pd.DataFrame(X, columns=['x', 'y', 'z'])
```

4

丟不要的值
把total跟time丟棄

5

放入標準化變數
用 StandarScaler.fit_transform()
去進行標準化的行為。(程式下方註
解有寫)

程 式 前 處 理

```
4     def get_frames(df, frame_size, hop_size):
115
116     N_FEATURES = 3
117
118     frames = []
119     labels = []
120     for i in range(0, len(df) - frame_size, hop_size):
121         x = df['x'].values[i: i + frame_size]
122         y = df['y'].values[i: i + frame_size]
123         z = df['z'].values[i: i + frame_size]
124         # 這行是做把兩秒兩秒的資料放在一個array
125
126         label = stats.mode(df['label'][i: i + frame_size])[0][0]
127         # 這行是為了符合前一項，就取label中出現最多次的，去當作我們的label。(相接處需要用到)
128
129         frames.append([x, y, z])
130         labels.append(label)
131         # 一起append是為了讓資料量相同
132
133     frames = np.asarray(frames).reshape(-1, frame_size, N_FEATURES)
134     # 這行是先把上面的array變成一行，然後做成200x3的陣列。
135     labels = np.asarray(labels)
136     # 這行是為了讓label跟上面的資料型態一樣。
137
138     return frames, labels
139
140 x, y = get_frames(scaled_X, frame_size, hop_size)
141 #把這兩個丟進X,y。
142
143 #把這兩個丟進X,y。
144 x, y = get_frames(scaled_X, frame_size, hop_size)
145
146
147
148 return frames, labels
```

6

一組一組捆起來

以前面設定的頻率跟跳躍點去把一組一組捆起來。

程 式 前 處 理

```
145 #資料總數/Hz*秒數 = 處理後的資料總數(也就是下方的859+215)
146 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 0, stratify = y)
147 # 這邊是將程式分成train跟validation
148
149 print(X_train.shape, X_test.shape)
150 print(X_train[0].shape, X_test[0].shape)
151
152 # 藉由上面的print看出怎麼分的，並且把X_train跟X_test reshape，為了讓數據符合CNN的model以及符合他的內容值，放入3維的值
153 X_train = X_train.reshape(859, 200, 3, 1)
154 X_test = X_test.reshape(215, 200, 3, 1)
155
156 # print(X_train[0].shape, X_test[0].shape)
157 # 檢查後會變成(200,3,1)
158
159 # 將要從這裏拿來訓練的資料切開成train和test
160 # 並且將他們的shape都改成(200,3,1)
161 # 並且將他們的shape都改成(200,3,1)
```

7

將訓練資料切出

將訓練及測試資料切開(82分)，並且把shape重新設定。



03

程 式 訓 練

程 式 訓 練

```
159 model = Sequential()
160 # 建立一個順序模型，是最簡單的模型，從頭到尾的結構順序。
161 model.add(Conv2D(16, kernel_size=(2, 2), activation = 'relu', input_shape = x_train[0].shape))
162 # 這是input層
163 # 使用Relu函數去掉負值，更能淬煉出物體的形狀
164 model.add(Dropout(0.1))
165 # Dropout就是在不同的訓練過程中隨機扔掉一部分神經元，也就是暫時不更新權重。
166 # Dropout是用來避免過度配適（overfitting）的。
167
168 model.add(Conv2D(32, kernel_size=(2, 2), activation='relu'))
169 model.add(Dropout(0.2))
170 # 第二層Convolution 層（32 個神經元）
171
172 model.add(Flatten())
173 # 將特徵值平攤
174
175 model.add(Dense(64, activation = 'relu'))
176 model.add(Dropout(0.5))
177 # 第三層Dense 層（64 個神經元）
178
179 model.add(Dense(3, activation='softmax'))
180 # output 3種結果
181
182 model.compile(optimizer=Adam(learning_rate = 0.001), loss = 'sparse_categorical_crossentropy', metrics = [ 'accuracy' ])
183 # 以compile函數定義損失函數(loss)、優化函數(optimizer)及成效衡量指標(metrics)
184
185 # 進行訓練，訓練過程會存在 train_history 變數中
186 history = model.fit(x_train, y_train, batch_size = 32, epochs = 30, validation_data= (x_test, y_test), verbose=1)
```

程式碼展示

程 式 訓 練

- Dense param 計算方法

```
total_params = (input_image_channels + 1) * number_of_filters
```

- Conv2D param 計算方法

```
total_params = (filter_height * filter_width * input_image_channels + 1) * number_of_filters
```

Model: "sequential"		
Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 199, 2, 16)	80
dropout (Dropout)	(None, 199, 2, 16)	0
conv2d_1 (Conv2D)	(None, 198, 1, 32)	2080
dropout_1 (Dropout)	(None, 198, 1, 32)	0
flatten (Flatten)	(None, 6336)	0
dense (Dense)	(None, 64)	405568
dropout_2 (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 3)	195
Total params: 407,923		
Trainable params: 407,923		
Non-trainable params: 0		

第一個param算法

```
Conv2D(16, kernel_size=(2, 2) ... )  
# (2*2*1+1)*16 = 80
```

第二個param算法

```
Conv2D(32, kernel_size=(2, 2) ... )  
# (2*2*16+1)*32 = 2080
```

先攤平

```
Flatten()  
# 198*1*32 param輸出0
```

第三個param算法

```
Dense(64 ... )  
# (6336+1)*64 = 405568
```

第四個param算法

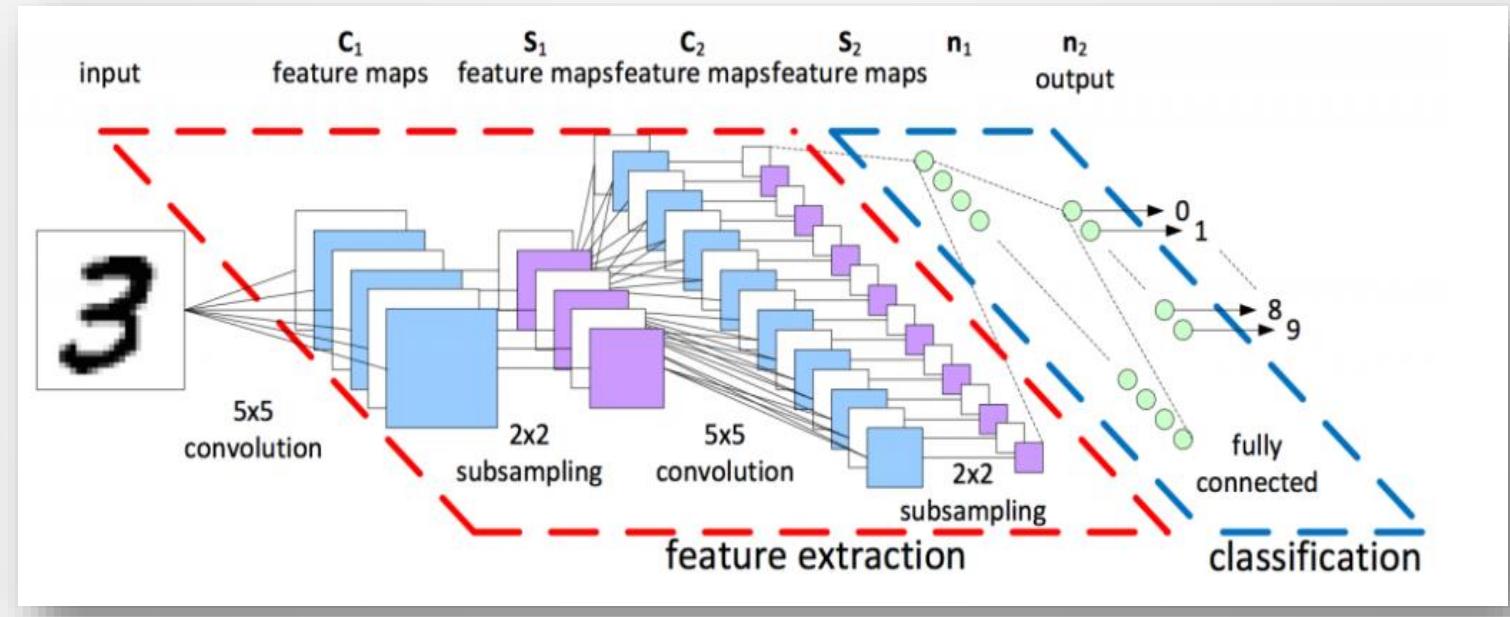
```
Dense(64 ... )  
# (64+1)*3 = 195
```

程 式 訓 練

什麼是CNN？

為什麼要用Flatten()攤平？

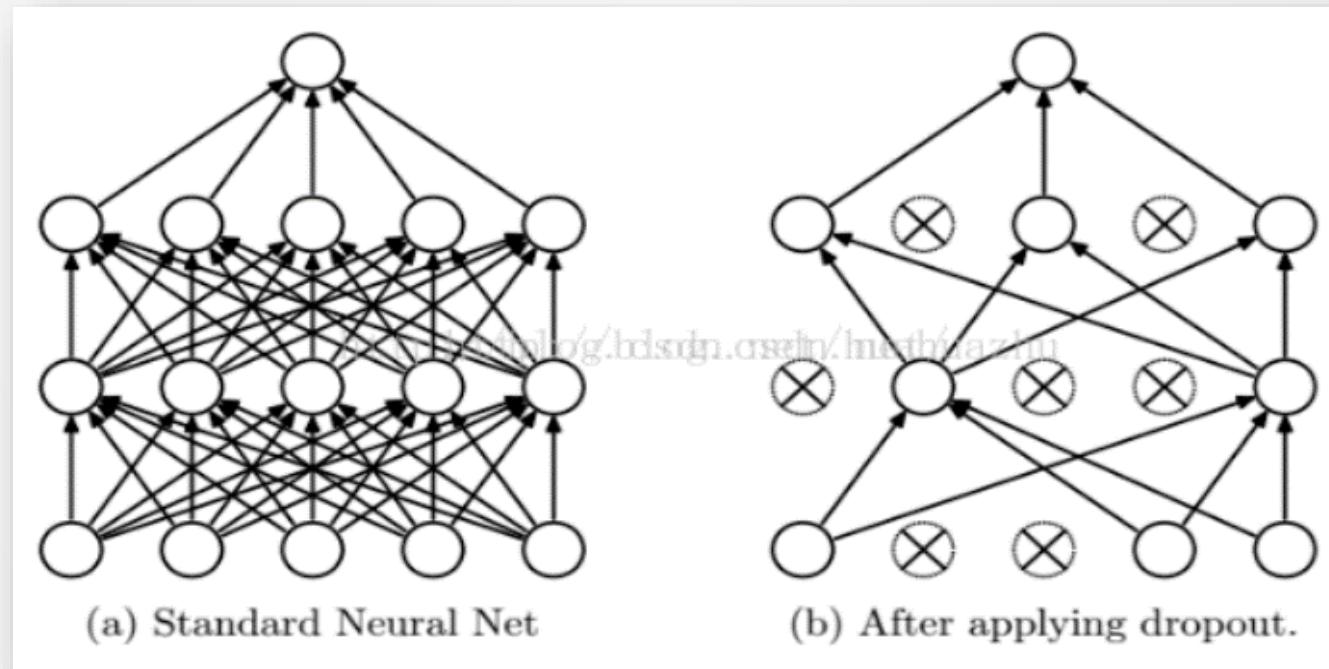
CNN是先用卷積把特徵抽取，進行MaxPooling或AvgPooling，最後再把特徵攤平，因此我們要用Flatten()。
輸入圖像→卷積組合→攤平(Flatten)→全連接層(Fully Connected layers)→分類



程 式 訓 練

Dropout是什麼？

Dropout就是在不同的訓練過程中隨機扔掉一部分神經元，也就是暫時不更新權重。用來避免過度配適（**Overfitting**）的。

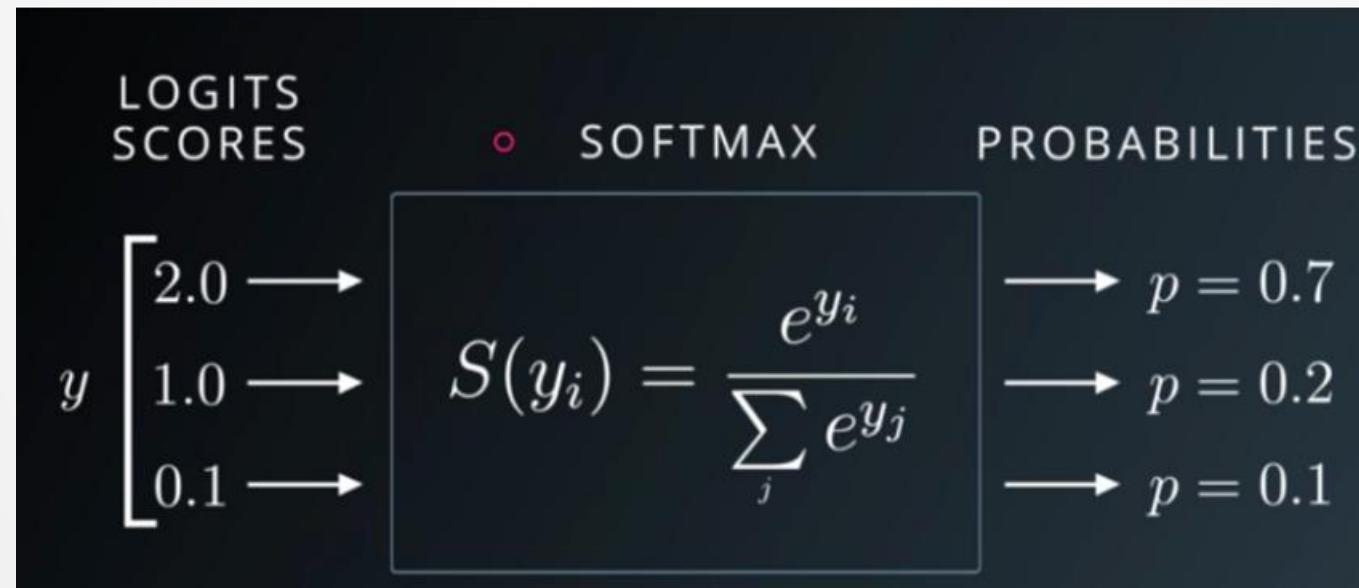


程 式 訓 練

全連接層主要在做最後的特徵提取，並且利用最後一層全連接層當作分類器。

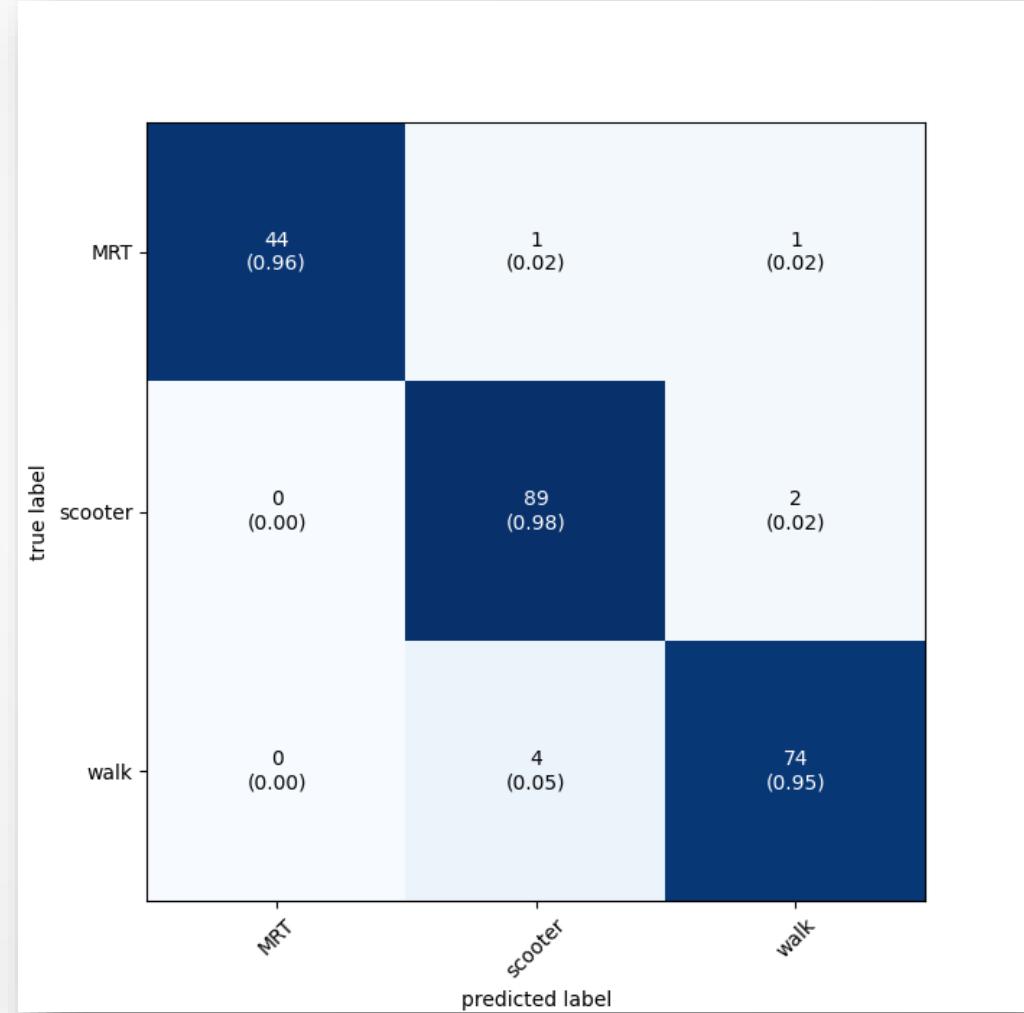
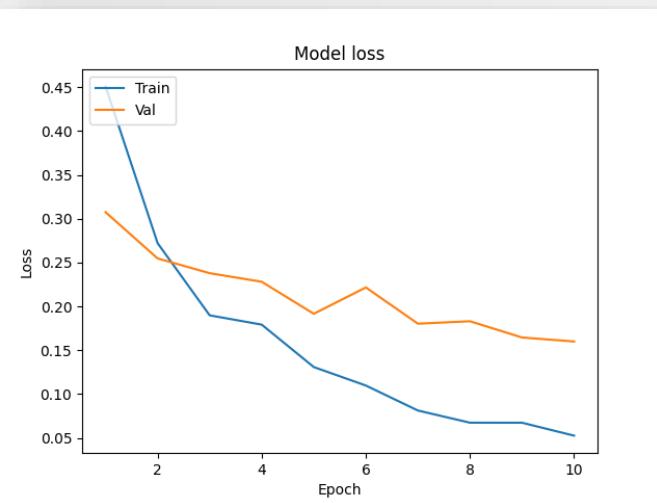
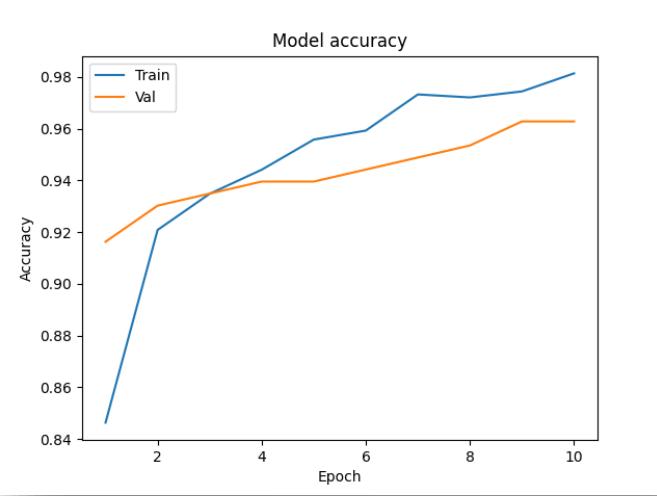
全連階層(Dense)，它的運算就是 $\text{output} = \text{activation}(\text{dot}(\text{input}, \text{kernel}) + \text{bias})$ ，即前面提到的 $y = g(x * W + b)$ 最後一層全連接層會使用SoftMax去進行分類。

Softmax原理，數值經過softmax function後，其加總值會變為1，因此，我們可以把各項的輸出值當作機率，而目標就是要縮小預測機率值與實際Label值，也就是老師之前ptt上課提到過的。



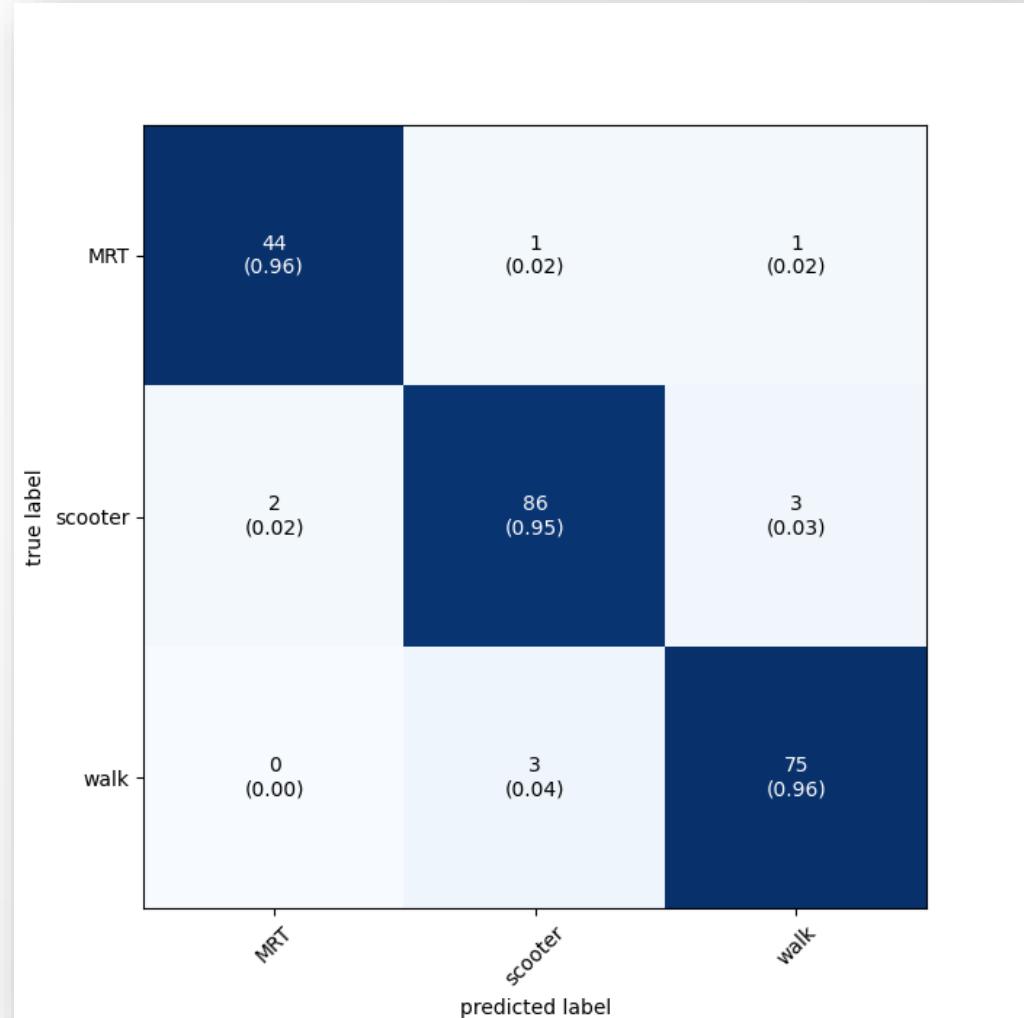
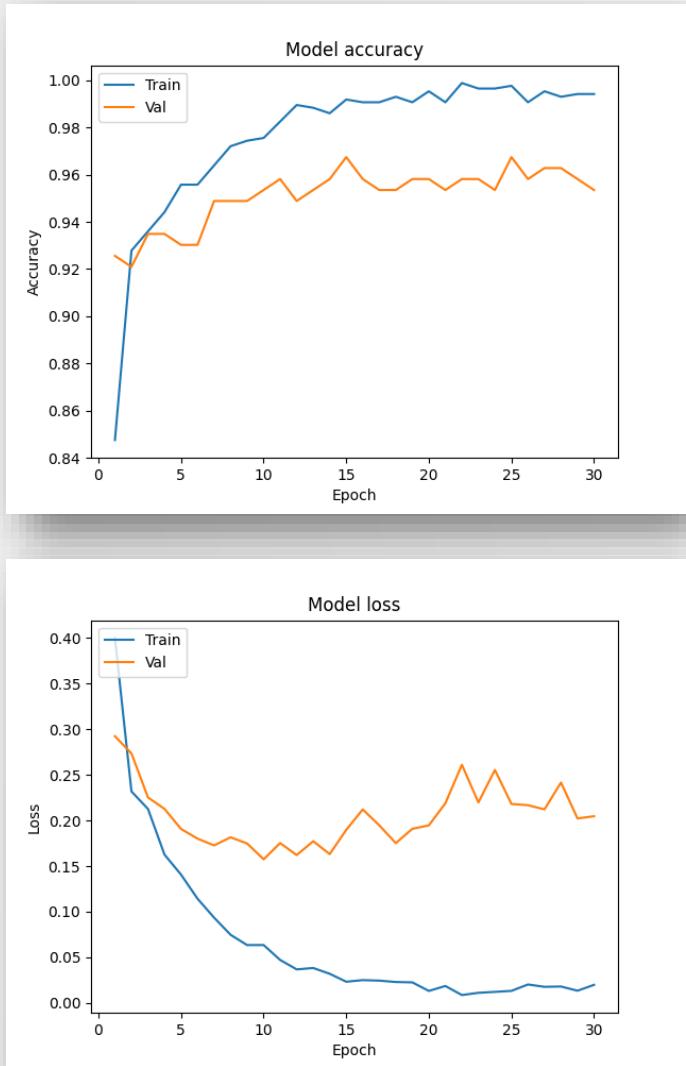
程 式 訓 練

10的圖表



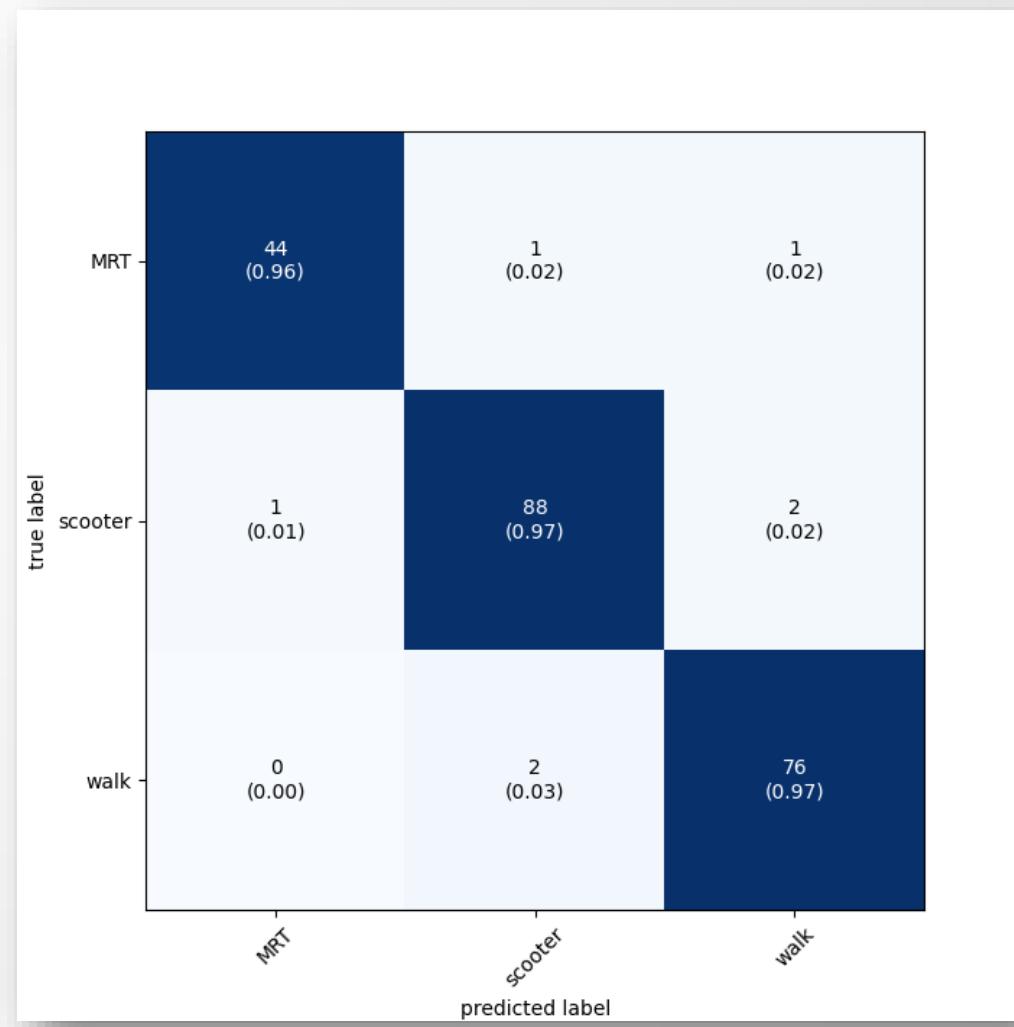
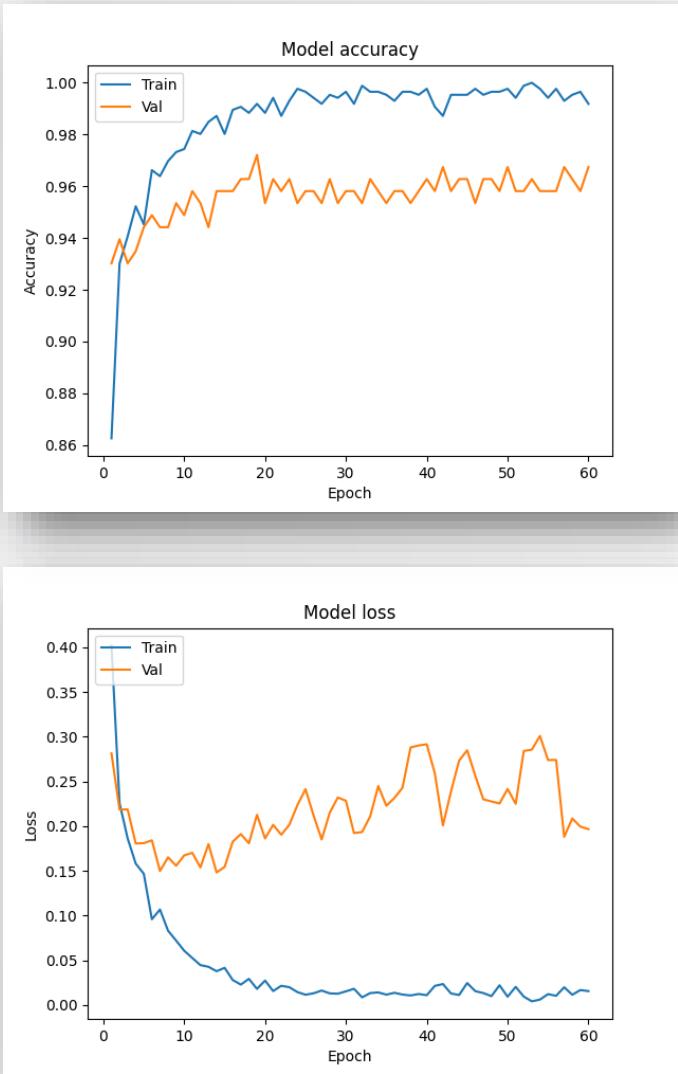
程 式 訓 練

30的圖表



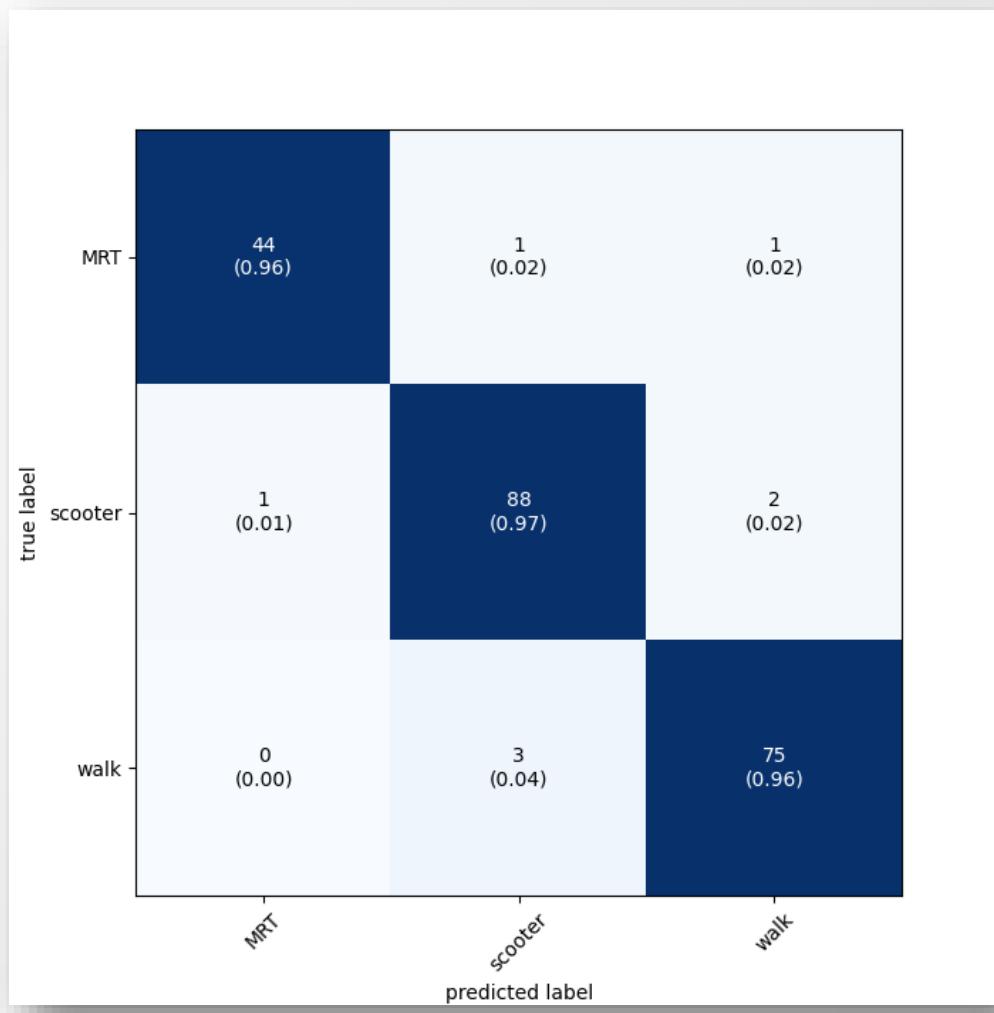
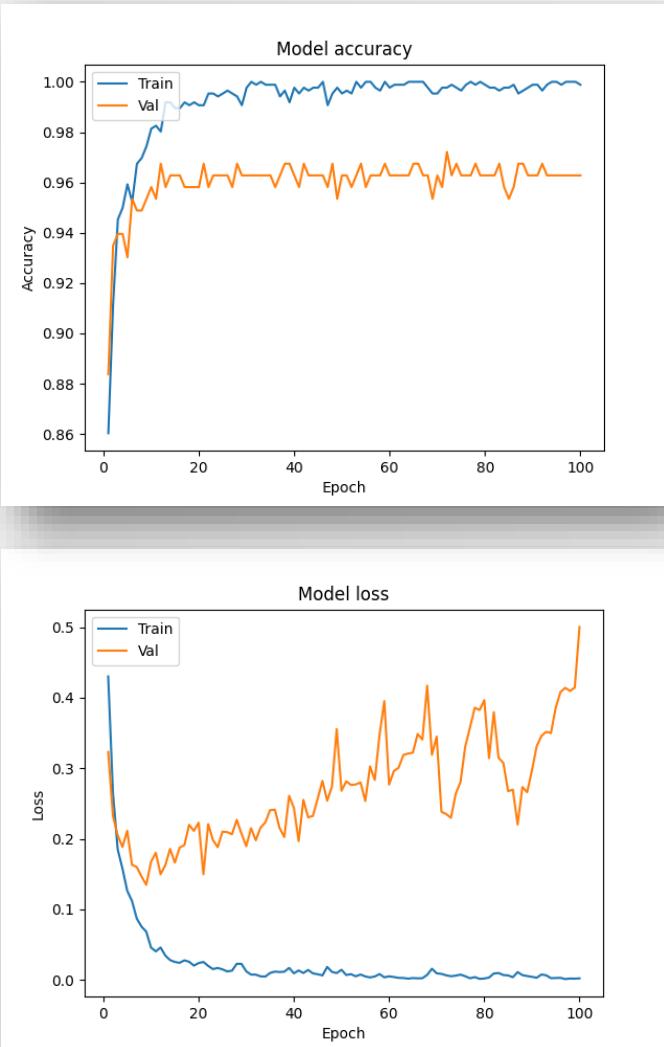
程 式 訓 練

60的圖表(train出來的最好範例)



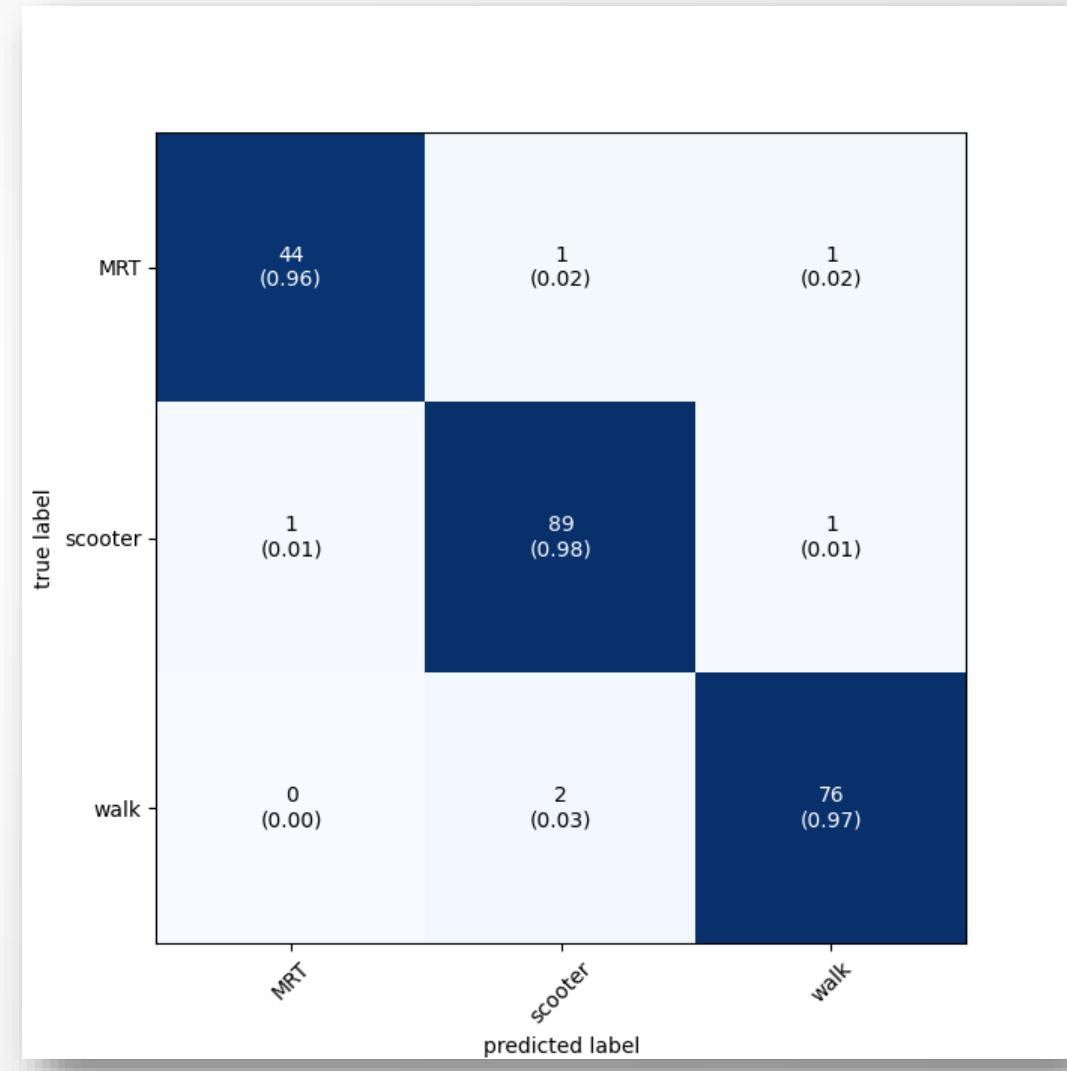
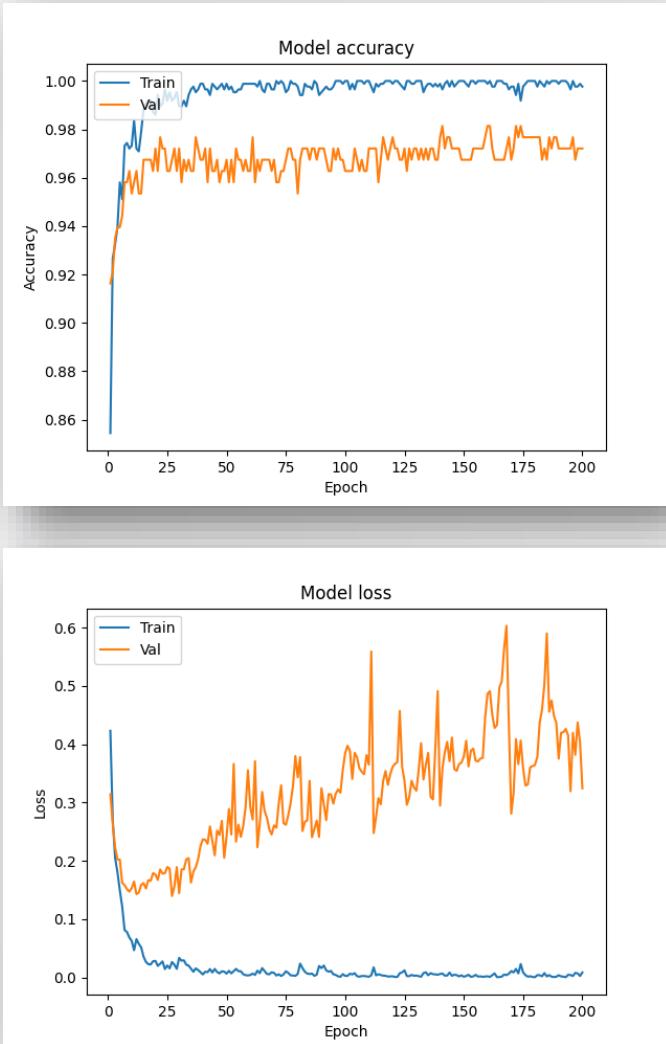
程 式 訓 練

100的圖表(看起來會overfitting)



程 式 訓 練

200的圖表(看起來會overfitting)





04

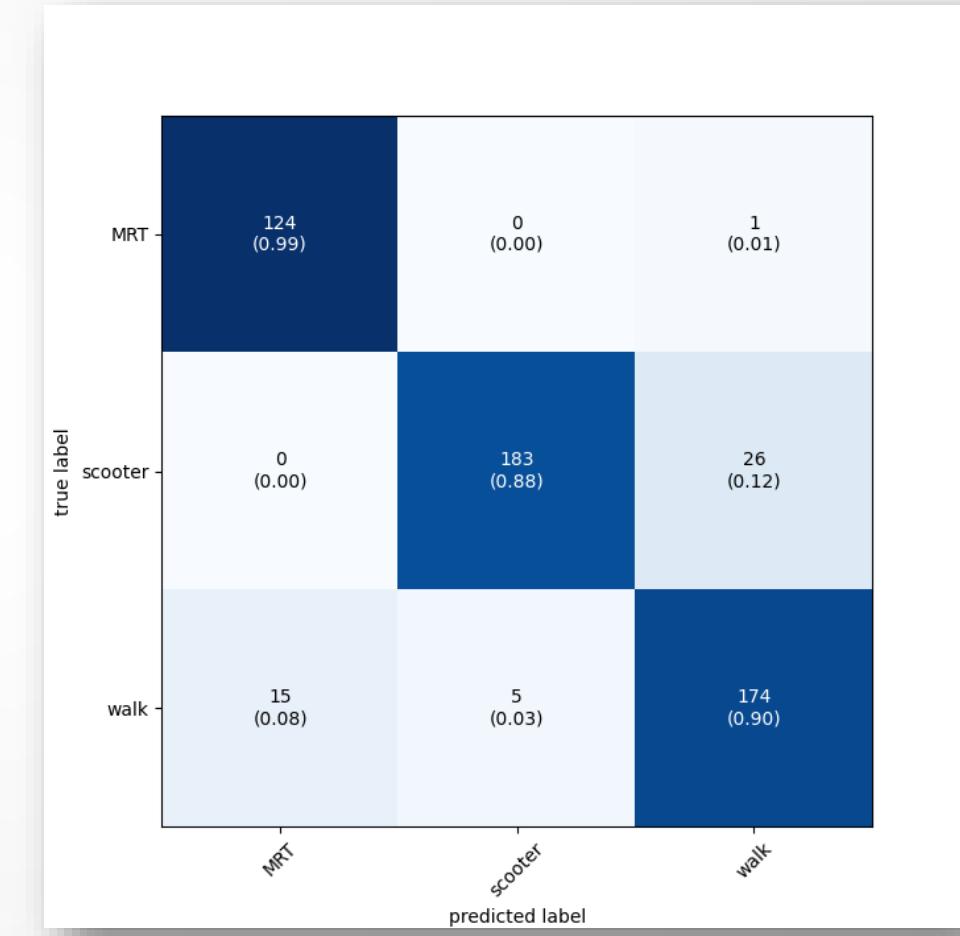
程 式 測 試

程 式 訓 練

epoch = 10的結果。

Model: "sequential"

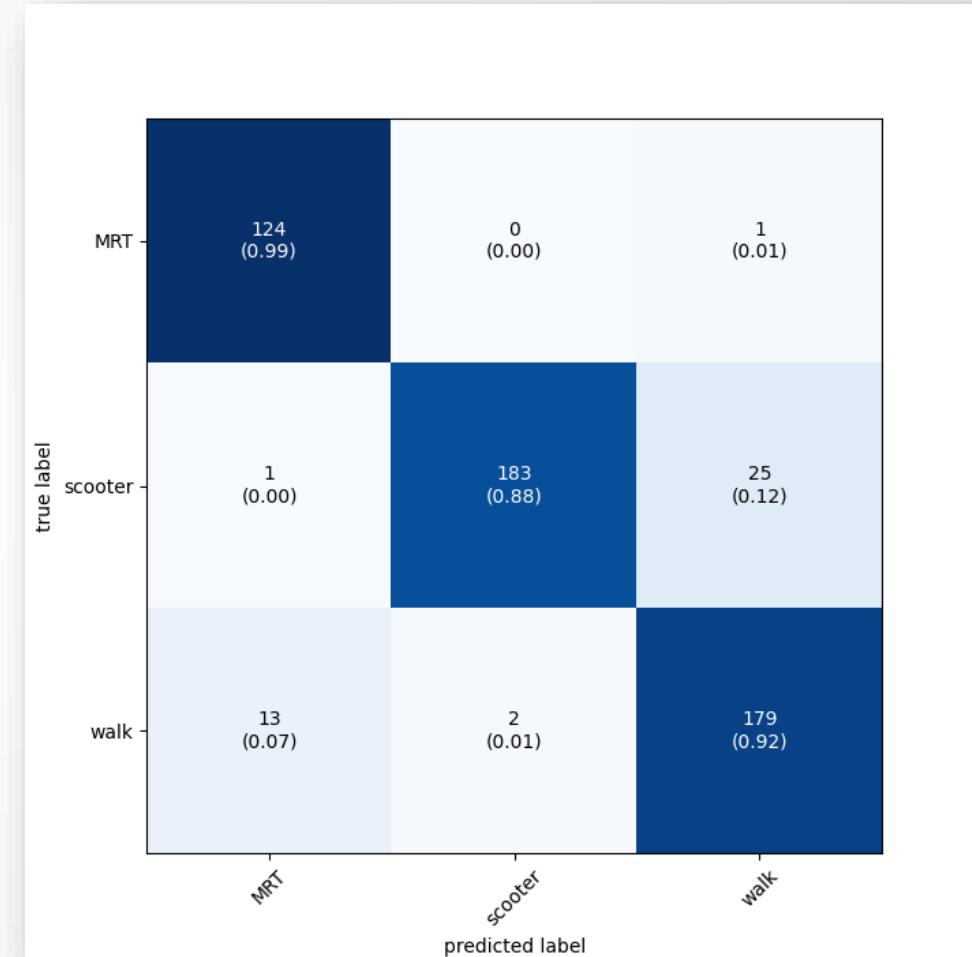
Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 199, 2, 16)	80
dropout (Dropout)	(None, 199, 2, 16)	0
conv2d_1 (Conv2D)	(None, 198, 1, 32)	2080
dropout_1 (Dropout)	(None, 198, 1, 32)	0
flatten (Flatten)	(None, 6336)	0
dense (Dense)	(None, 64)	405568
dropout_2 (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 3)	195
Total params: 407,923		
Trainable params: 407,923		
Non-trainable params: 0		
mission success rate = 91.10%		



程 式 訓 練

epoch = 30的結果。

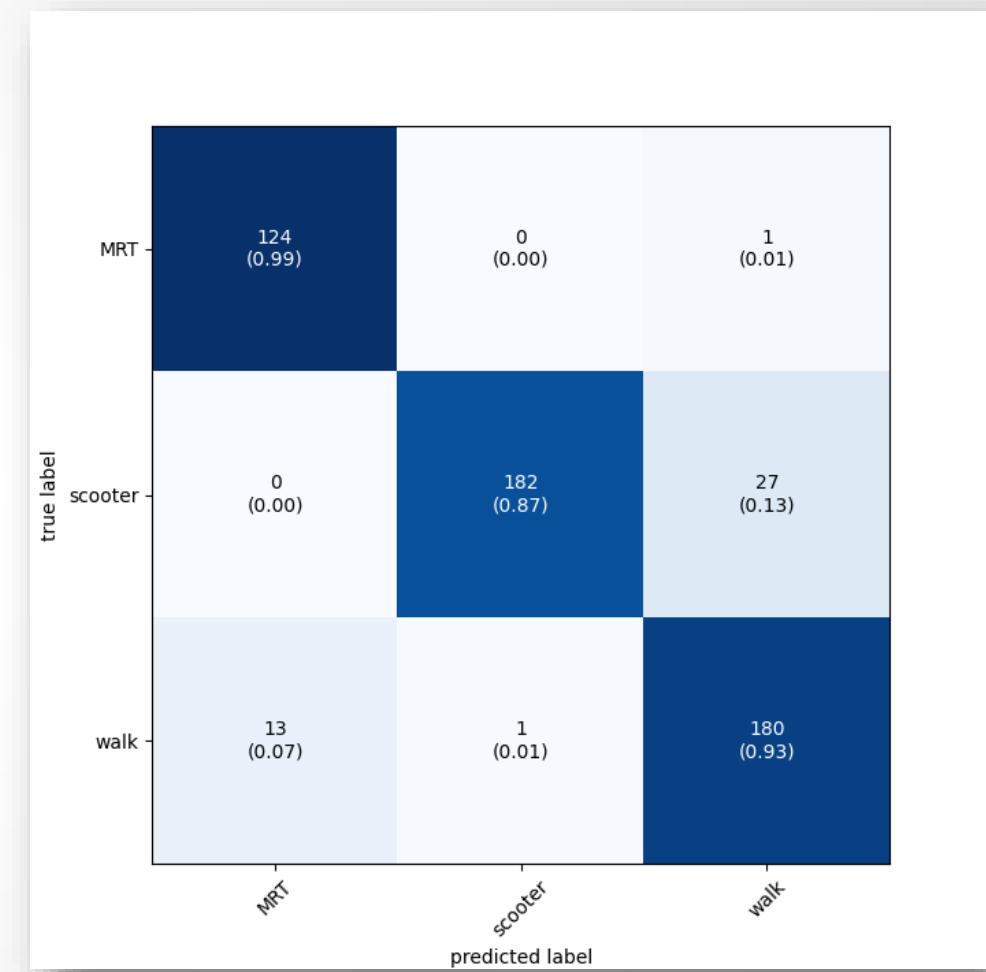
```
Model: "sequential"
Layer (type)      Output Shape       Param #
conv2d (Conv2D)    (None, 199, 2, 16)   80
dropout (Dropout)  (None, 199, 2, 16)   0
conv2d_1 (Conv2D)   (None, 198, 1, 32)   2080
dropout_1 (Dropout) (None, 198, 1, 32)   0
flatten (Flatten)  (None, 6336)         0
dense (Dense)      (None, 64)           405568
dropout_2 (Dropout) (None, 64)           0
dense_1 (Dense)    (None, 3)            195
Total params: 407,923
Trainable params: 407,923
Non-trainable params: 0
mission success rate = 92.05%
```



程 式 訓 練

epoch = 60的結果。

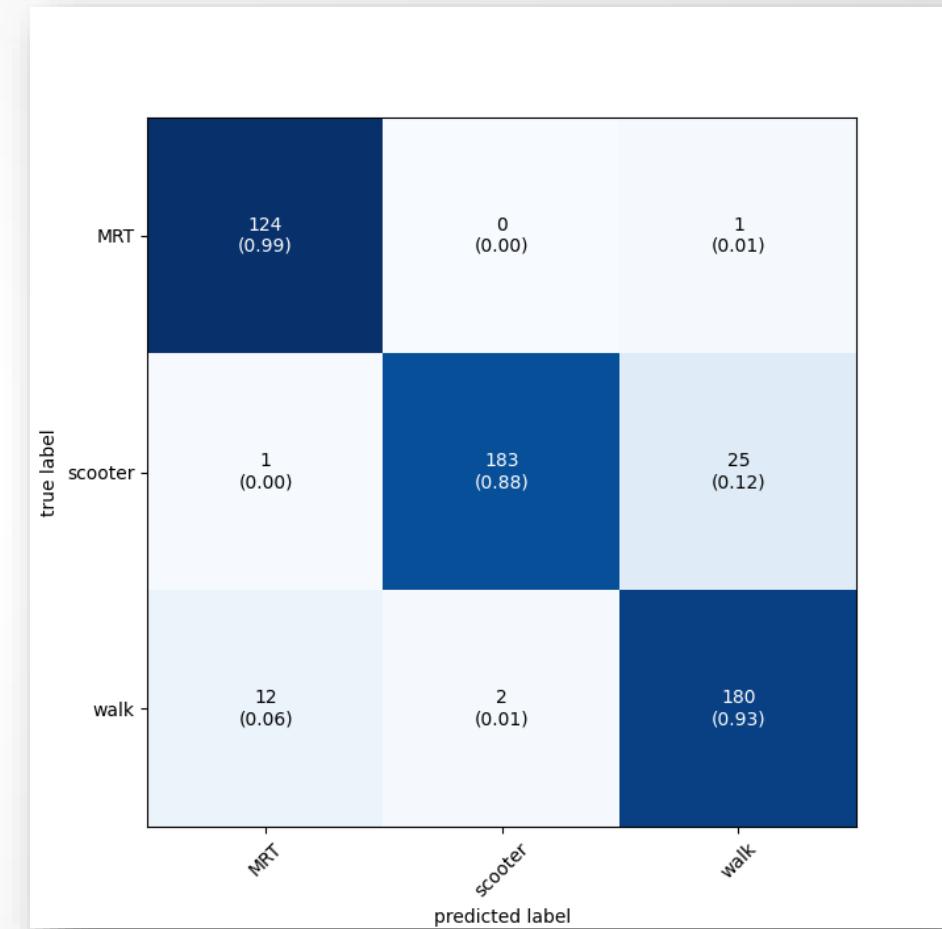
```
Model: "sequential"
Layer (type)          Output Shape         Param #
conv2d (Conv2D)        (None, 199, 2, 16)      80
dropout (Dropout)      (None, 199, 2, 16)      0
conv2d_1 (Conv2D)       (None, 198, 1, 32)     2080
dropout_1 (Dropout)     (None, 198, 1, 32)     0
flatten (Flatten)      (None, 6336)           0
dense (Dense)          (None, 64)             405568
dropout_2 (Dropout)     (None, 64)             0
dense_1 (Dense)         (None, 3)              195
Total params: 407,923
Trainable params: 407,923
Non-trainable params: 0
mission success rate = 92.05%
```



程 式 訓 練

epoch = 100的結果。

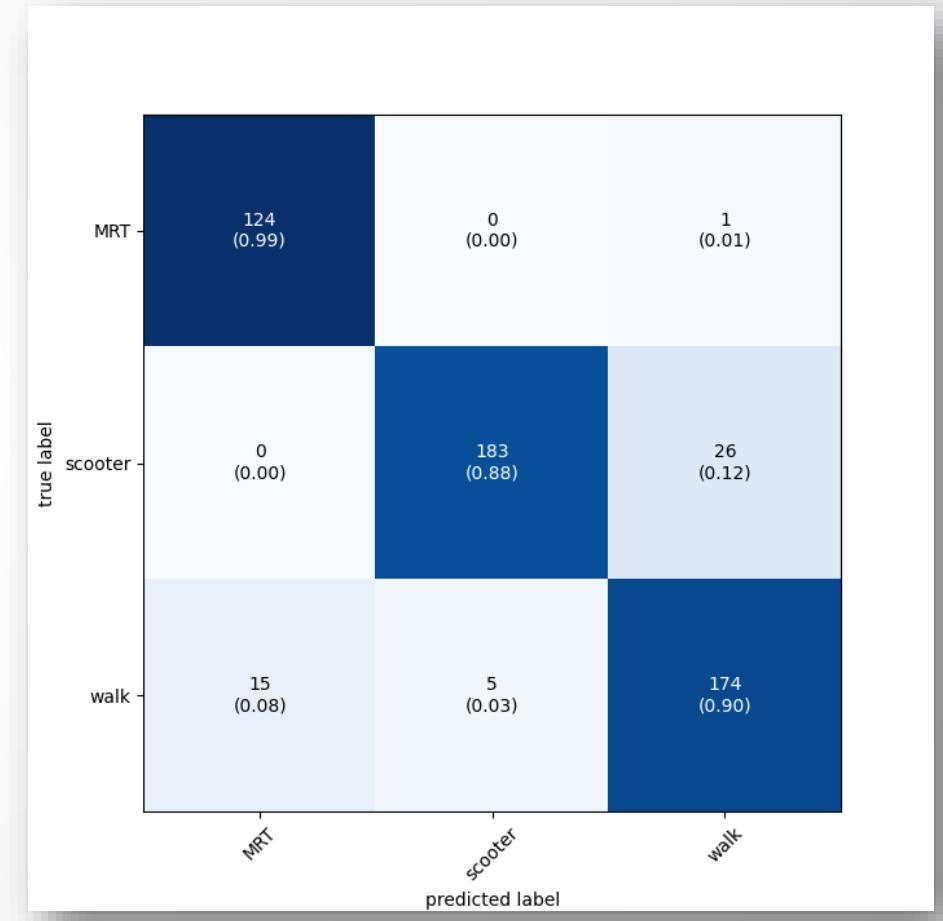
```
Model: "sequential"
Layer (type)          Output Shape       Param #
conv2d (Conv2D)        (None, 199, 2, 16)    80
dropout (Dropout)      (None, 199, 2, 16)    0
conv2d_1 (Conv2D)       (None, 198, 1, 32)   2080
dropout_1 (Dropout)     (None, 198, 1, 32)   0
flatten (Flatten)      (None, 6336)         0
dense (Dense)          (None, 64)           405568
dropout_2 (Dropout)     (None, 64)           0
dense_1 (Dense)         (None, 3)            195
Total params: 407,923
Trainable params: 407,923
Non-trainable params: 0
mission success rate = 92.23%
```



程 式 訓 練

epoch = 200的結果。(overfitting)

```
Model: "sequential"
Layer (type)      Output Shape       Param #
conv2d (Conv2D)    (None, 199, 2, 16)   80
dropout (Dropout)  (None, 199, 2, 16)   0
conv2d_1 (Conv2D)   (None, 198, 1, 32)  2080
dropout_1 (Dropout) (None, 198, 1, 32)  0
flatten (Flatten)  (None, 6336)        0
dense (Dense)      (None, 64)          405568
dropout_2 (Dropout) (None, 64)          0
dense_1 (Dense)    (None, 3)           195
Total params: 407,923
Trainable params: 407,923
Non-trainable params: 0
mission success rate = 91.10%
```



問題與討論：

前面認為會overfitting的事情，結果實際test發現反而結果更好，令人詫異，值得拿出來分享一下。

分別為

10epochs = 91.10%

30epochs = 92.05%

60epochs = 92.05%

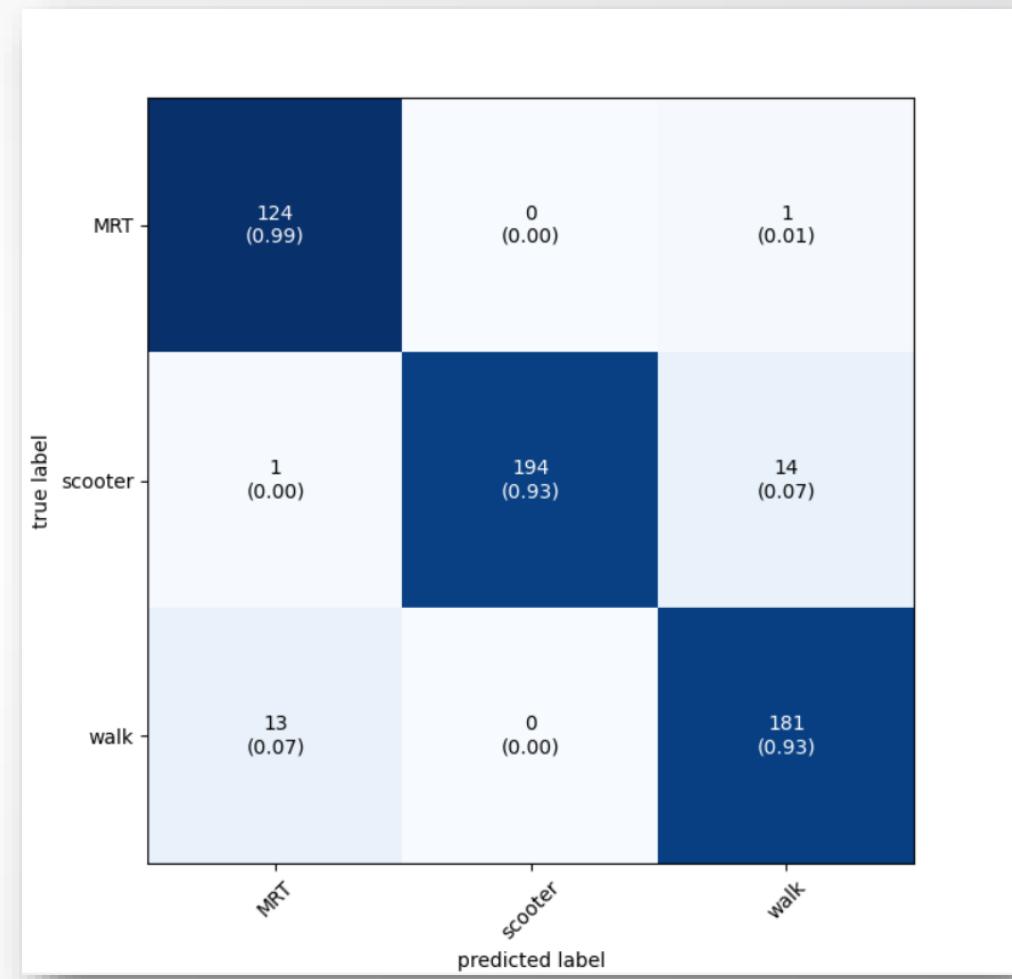
100epochs = 92.23% (best)

200epochs = 91.10%

程 式 訓 練

我把dropout值改低成 0.6 後，大約在94%，但有時候是89%左右，我覺得很奇怪，於是想用別的值測測看。

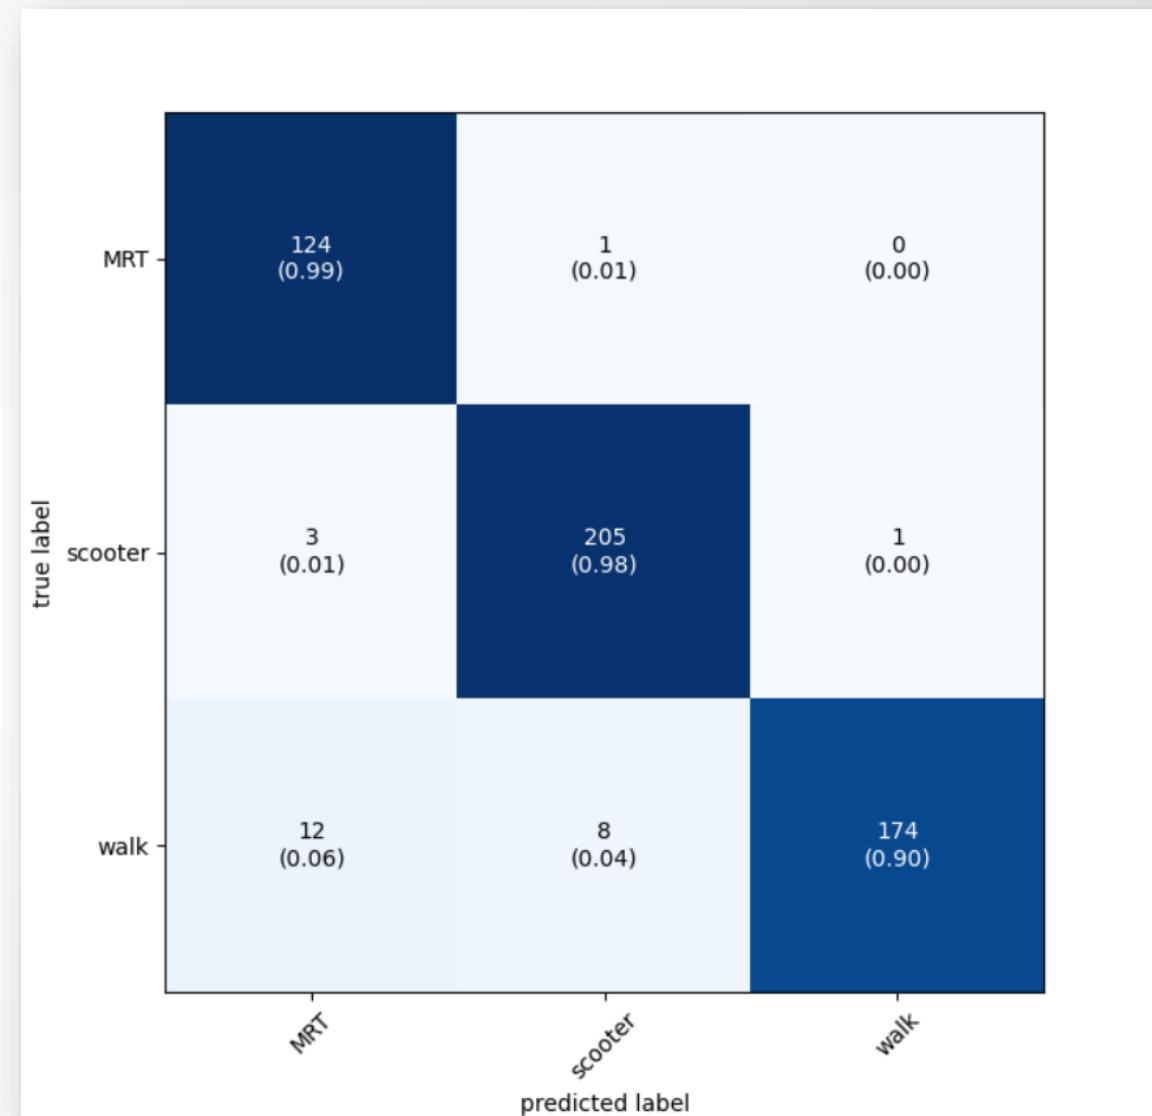
```
Model: "sequential"
Layer (type)      Output Shape       Param #
=====            ======           =====
conv2d (Conv2D)   (None, 199, 2, 16)    80
dropout (Dropout) (None, 199, 2, 16)    0
conv2d_1 (Conv2D) (None, 198, 1, 32)    2080
dropout_1 (Dropout) (None, 198, 1, 32)    0
flatten (Flatten) (None, 6336)          0
dense (Dense)     (None, 64)           405568
dropout_2 (Dropout) (None, 64)           0
dense_1 (Dense)   (None, 3)            195
=====
Total params: 407,923
Trainable params: 407,923
Non-trainable params: 0
mission success rate = 94.51%
```



程 式 訓 練

我把dropout值改低成 0.3 後，我就成功上升成95.08%，但我覺得這可能只是運氣，多嘗試幾次後發現會上下起伏，也有測到90%過。
只是剛好loss的部分是對的，他丟掉了卻學對了。

```
Model: "sequential"
Layer (type)          Output Shape       Param #
conv2d (Conv2D)        (None, 199, 2, 16)    80
dropout (Dropout)      (None, 199, 2, 16)    0
conv2d_1 (Conv2D)       (None, 198, 1, 32)   2080
dropout_1 (Dropout)     (None, 198, 1, 32)   0
flatten (Flatten)      (None, 6336)         0
dense (Dense)          (None, 64)           405568
dropout_2 (Dropout)     (None, 64)           0
dense_1 (Dense)         (None, 3)            195
Total params: 407,923
Trainable params: 407,923
Non-trainable params: 0
mission success rate = 95.27%
```



程 式 訓 練

上網查了average_pooling2d&global_average_pooling2d用起來覺得效果很好，成功率上升到97.16%，並且我的loss值也符合了期待。

```
model = Sequential()
# 建立一個順序模型，是最簡單的模型，從頭到尾的結構順序。
model.add(Conv2D(filters=16,kernel_size=(3,3),strides=(1,1),padding="same", activation = 'relu', input_shape = X_train[0].shape))
# 這是input層
# 使用relu函數去掉負值，更能淬煉出物體的形狀
model.add(AveragePooling2D(pool_size=(2,2)))
#AveragePooling2D是為了平均整體值，減少誤差。
model.add(Dropout(0.5))
# Dropout就是在不同的訓練過程中隨機扔掉一部分神經元，也就是暫時不更新權重。
# Dropout是用來避免過度配適(Overfitting)的。

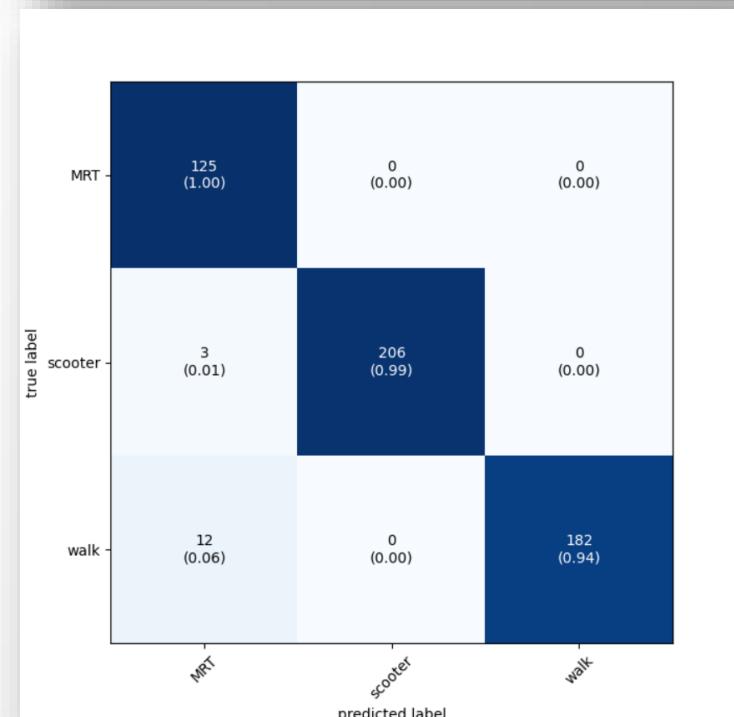
model.add(Conv2D(filters=32,kernel_size=(3,3),strides=(1,1),padding="same", activation='relu'))
model.add(Dropout(0.5))
# 第二層Convolution 層 (32 個神經元)
model.add(GlobalAveragePooling2D())
#model.add(Flatten())
# 將特徵值平攤，GlobalAveragePooling2D去做。

model.add(Dense(64, activation = 'relu'))
model.add(Dropout(0.5))
# 第三層Dense 層 (64 個神經元)

model.add(Dense(3, activation='softmax'))
# output 3種結果

model.compile(optimizer=Adam(learning_rate = 0.001), loss = 'sparse_categorical_crossentropy', metrics = ['accuracy'])
# 以compile函數定義損失函數(loss)、優化函數(optimizer)及成效衡量指標(metrics)
```

```
Model: "sequential"
Layer (type)          Output Shape         Param #
conv2d (Conv2D)        (None, 200, 3, 16)      160
average_pooling2d (AveragePooling2D) (None, 100, 1, 16) 0
dropout (Dropout)      (None, 100, 1, 16)      0
conv2d_1 (Conv2D)       (None, 100, 1, 32)     4640
dropout_1 (Dropout)    (None, 100, 1, 32)     0
global_average_pooling2d (GlobalAveragePooling2D) (None, 32) 0
dense (Dense)          (None, 64)            2112
dropout_2 (Dropout)    (None, 64)            0
dense_1 (Dense)         (None, 3)             195
Total params: 7,107
Trainable params: 7,107
Non-trainable params: 0
mission success rate = 97.16%
```



Average Pooling

亦稱Mean pooling，也就是Average pooling，做法也很簡單，就是將滑動視窗框選到的矩陣值加總，然後計算平均即可。

4	8	9	8
5	7	7	6
1	2	7	8
3	5	5	5

8	9
5	8



Maximum Pooling

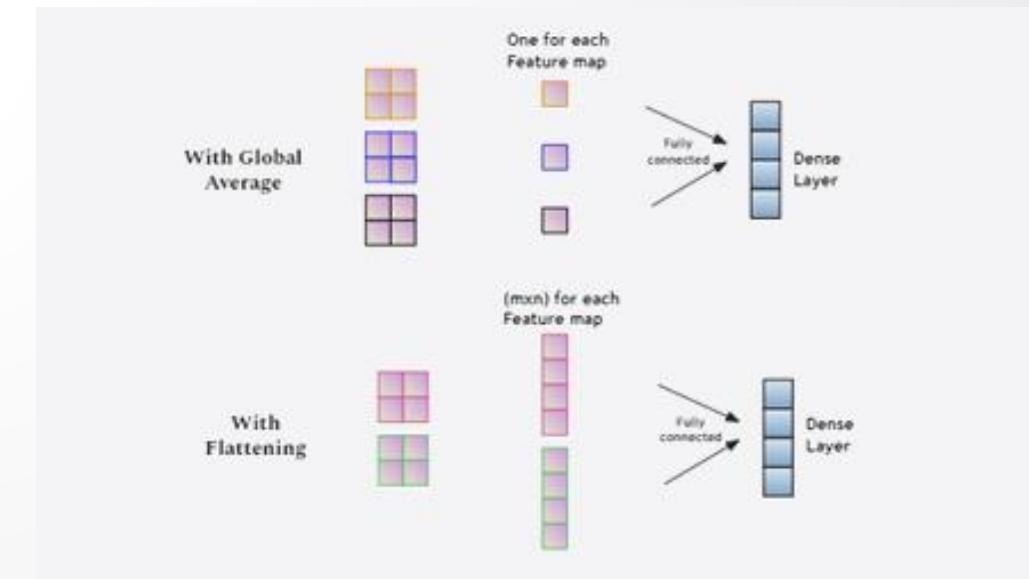
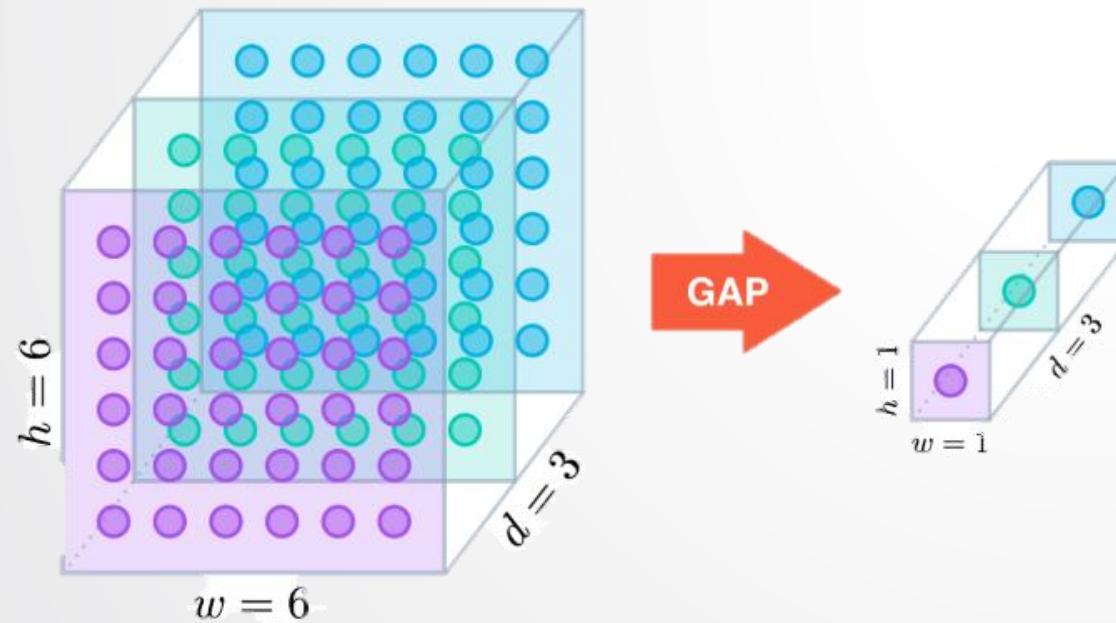
6	7.5
2.75	6.25

Average Pooling

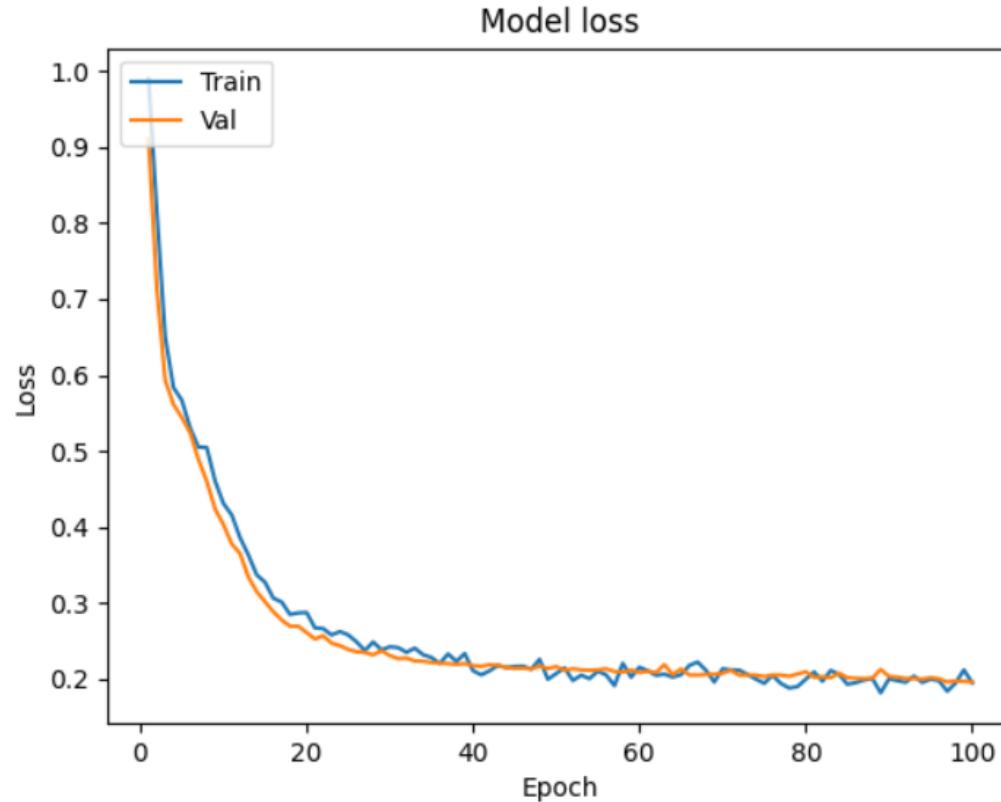
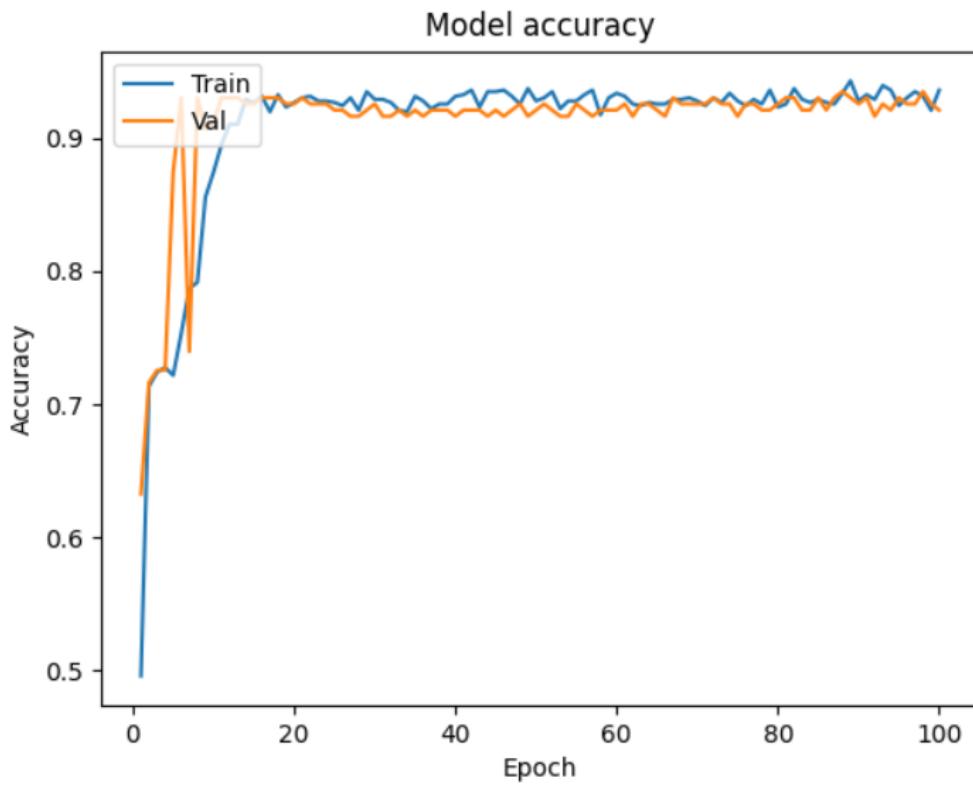
Global Average Pooling

簡稱GAP，簡單說，就是卷積層後，一種可以取代全連接層（FC）的作法。
主要就是可以減少參數，降低overfit。

假設卷積層的最後輸出是 $h \times w \times d$ 的三維特徵圖，具體大小為 $6 \times 6 \times 3$ ，經過GAP轉換後，變成了大小為 $1 \times 1 \times 3$ 的輸出值，也就是每一層 $h \times w$ 會被平均化成一個值。



程 式 訓 練



2021

Thanks for watching

C N N
陳 茲 窜